

Cross-Lingual Code Retrieval Bahasa Indonesia-Python berbasis Multilingual E5 Embedding

Perolehan Informasi Lanjut

Azhary Arliansyah ▪ Magister Ilmu Komputer - Universitas Indonesia



Outline

Recap - RQ, Metodologi, Skenario

Analisis Hasil - Embedding

Analisis Hasil - Translasi

Kesimpulan dan Limitasi

Appendix

Problem Statement

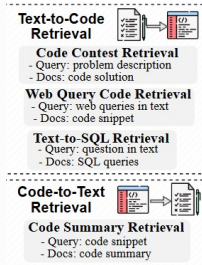
- ▶ Alat pencarian konvensional (seperti *grep* atau fitur pencarian dasar pada IDE) hanya mengandalkan kecocokan leksikal (*string matching*)
- ▶ Dokumentasi seringkali tidak lengkap, memaksa pengembang untuk mencari jawaban langsung di dalam *source code*

Research Questions

- ▶ RQ1: Bagaimana performa Multilingual E5 Model dalam tugas Cross-Lingual Code Retrieval dalam pencarian kode Python menggunakan kueri Bahasa Indonesia?
- ▶ RQ2: Apakah metode translasi kueri berpengaruh dalam memaksimalkan performa Code Retrieval?

Metodologi: Model

- ▶ Menggunakan Multilingual E5 Model sebagai text embeddings (Wang et al., 2024)
- ▶ Menerjemahkan kueri ke Bahasa Indonesia menggunakan:
 - ▶ Open-Source Neural Machine Translation Model: **opus-mt-en-id**
 - ▶ LLM: Gemma, menggunakan instruksi (prompt) untuk menerjemahkan kueri
- ▶ Menggunakan **coir-eval** (Li et al., 2024) library yang dirancang khusus untuk evaluasi Code Retrieval, dan fokus pada metrik NDCG@10



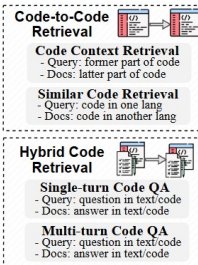
4 main tasks
8 sub-tasks
10 datasets




CoIR Benchmark

14 main languages:

python, sql, go, java, js,
c, css, php, c++, html,
rust, shell, swift, ruby



Alur Metodologi



Ringkasan Konfigurasi Model

Evaluasi dilakukan pada enam konfigurasi:

- ▶ **e5-base-v2 (monolingual)**

- ▶ Query English
- ▶ Query hasil translasi gemma-2b-it
- ▶ Query hasil translasi opus-mt-en-id

- ▶ **multilingual-e5-base**

- ▶ Query English
- ▶ Query hasil translasi gemma-2b-it
- ▶ Query hasil translasi opus-mt-en-id

Fokus metrik evaluasi:

- ▶ **NDCG@10**

- ▶ Dataset yang akan digunakan adalah **CoSQA** (Huang et al., 2021), yang digunakan untuk *text-to-code retrieval*
- ▶ qrels terdiri dari **19k training**, dan **500 testing**
- ▶ Bahasa pemrograman pada dataset tersebut adalah **Python**
- ▶ Kueri pada dataset tersebut berbahasa Inggris

Gemma Prompt


*"Translate the English query into Bahasa Indonesia.
Return ONLY the translated sentence. No explanation.
No notes. No extra text.
English: {english_query}
Bahasa Indonesia:"*

Analisis Hasil - Bahasa Indonesia pada E5-base-v2

Query	NDCG@10
English	0.332
Gemma-translation	0.135
OPUS-translation	0.077

- ▶ Gemma: penurunan **0.197**
- ▶ OPUS: penurunan **0.255**
- ▶ e5-base-v2 adalah model *non-multilingual*.
- ▶ Embedding Bahasa Indonesia menjadi tidak representatif.

e5-base-v2 tidak cocok untuk Cross-Lingual Code Retrieval.




Analisis Hasil - Bahasa Indonesia pada Multilingual-E5-base

Query	NDCG@10
English	0.315
Gemma-translation	0.235
OPUS-translation	0.213

► Gemma: penurunan **0.080**

► OPUS: penurunan **0.102**

Model multilingual jauh lebih stabil terhadap variasi bahasa dan noise translasi.




Analisis Hasil - Gemma vs OPUS Translation


Model	Gemma	OPUS	Pemenang
e5-base-v2	0.135	0.077	Gemma
multilingual-e5	0.235	0.213	Gemma

- ▶ OPUS melakukan translasi secara literal.
- ▶ Gemma menghasilkan translasi yang:
 - ▶ lebih natural
 - ▶ lebih sesuai formulasi manusia
 - ▶ lebih kaya semantik.

Translasi Gemma yang lebih natural dan semantik membuat embedding kueri lebih similar dengan representasi embedding kode, sehingga retrieval lebih relevan dan NDCG@10 lebih tinggi



(a) E5 Embedding Drift



(b) Multilingual E5 Embedding Drift

Analisis Hasil - E5-base-v2 vs Multilingual-E5-base

Pada kueri Bahasa Indonesia (Gemma translation):

Model	NDCG@10 (Indo)
e5-base-v2	0.135
multilingual-e5-base	0.235

- ▶ Multilingual-E5 menang signifikan.
- ▶ Model monolingual gagal melakukan *alignment* antar bahasa.

Kemampuan multilingual lebih cocok untuk cross-lingual IR.

Analisis Hasil - Findings

- ▶ *Cross-lingual* retrieval sangat dipengaruhi kemampuan model memahami bahasa kueri.
- ▶ Multilingual-E5 menunjukkan hasil jauh lebih baik dibanding e5-base.
- ▶ Translasi membantu, tetapi masih belum mengungguli kueri asli English.
- ▶ Gemma menghasilkan terjemahan yang lebih sesuai semantik dengan representasi embedding kode sehingga menghasilkan performa IR lebih baik dari pada terjemahan literal oleh OPUS.

Multilingual embedding + LLM (Gemma) translation = kombinasi terbaik untuk Bahasa Indonesia.

Analisis Kategori Error Translasi

Kategori Error	Deskripsi
Terminology Error	Kesalahan terjemahan token teknis (fungsi, library, keyword)
Literal Translation	Terjemahan kata demi kata, tidak natural
Omission	Informasi penting hilang dari kueri
Hallucination	MT menambahkan informasi yang tidak ada di kueri

Table: Kategori error translasi menurut American Translators Associations (ATA)

Kategori	Query EN	Query ID
Terminology	hash a string using SHA1	mengacak string menggunakan SHA1
Literal	sort a list in Python	urut daftar di Python
Omission	reverse a linked list	membalik linked list
Hallucination	merge arrays	gabungkan array berdasarkan key

Table: Contoh kueri untuk tiap kategori error

Contoh Kueri

ID	English	opus-mt-en-id	Gemma	Dampak IR
q20110	how to save header of fits file to export python	bagaimana menyimpan header dari berkas cocok ke ekspor python (" <i>fits</i> " → <i>rusak</i>)	bagaimana untuk menyimpan header dari file fits untuk diexport python? (<i>token utuh</i>)	OPUS merusak token teknis → informasi semantik berubah (<i>OPUS: terminology_error</i> , <i>Gemma: no_error</i>).
q20136	python3 ctypes return float array	python3 ctype mengembalikan array float (<i>typo pada library</i>)	python3 ctypes return float array (<i>tidak diterjemahkan</i>)	Typo pada nama library → kode tidak cocok (<i>OPUS: terminology_error</i> , <i>Gemma: no_error</i>).
q20127	python flatten a nested dictionary	python flatten sebuah dictionary nested (<i>campuran bahasa</i>)	python flatten a nested dictionary (<i>tidak diterjemahkan</i>)	Campuran Indo-Inggris → embedding tidak stabil → hasil pencarian bising (<i>OPUS: literal_translation</i> , <i>Gemma: literal_translation/no_error</i>).
q20114	python check all items in list are ints	Python memeriksa semua butir dalam daftar adalah int (<i>literal</i>)	apa yang dilakukan dengan list ini? (<i>makna berubah</i>)	Gemma mengubah makna → informasi semantik berubah (<i>OPUS: no_error</i> , <i>Gemma: hallucination + omission</i>).
q20156	python numpy masked validating	python numpy mastomed vailding (<i>garbled</i>)	Python NumPy masked validating	Kedua terjemahan tetap rusak → embedding tidak bermakna → retrieval gagal (<i>OPUS: terminology_error + hallucination</i> , <i>Gemma: no_error</i>).
q20171	python hashlib calc sha1 of file	python hashlib calc sha1 dari berkas	python hashlib calc sha1 dari file	Token teknis terjaga → makna tetap → kinerja IR aman (<i>OPUS: no_error</i> , <i>Gemma: no_error</i>).



Statistik Kategori Error Translasi

OPUS:


- ▶ Mayoritas kesalahan OPUS berupa *hallucinations*: MT menambahkan informasi yang tidak ada di kueri.
- ▶ Kesalahan *terminology error* lebih sedikit.

Gemma:


- ▶ Gemma juga memiliki mayoritas *hallucinations*, tetapi sedikit lebih banyak *terminology error* dibanding OPUS.
- ▶ *Literal translation* dan *omission* rendah: Gemma menjaga token teknis lebih baik dan hasil IR lebih stabil.



Embedding Drift vs. Code Retrieval Performance



multilingual-e5-base




e5-base-v2

- ▶ OPUS menghasilkan *drift* yang lebih kecil dibanding Gemma terhadap kueri bahasa Inggris, tetapi NDCG@10 untuk kueri translasi justru lebih rendah.
- ▶ Multilingual-e5 lebih *robust*: meskipun Gemma memberi drift lebih besar, performa retrieval (NDCG@10) tetap lebih baik daripada OPUS dan jauh di atas e5-base untuk kueri bahasa Indonesia.
- ▶ Hal ini menunjukkan bahwa *similarity* embedding *cross-lingual* (seperti *English vs Indonesian query*) tidak otomatis berhubungan positif dengan kualitas code retrieval. Namun, yang lebih penting adalah seberapa baik representasi embedding kueri translasi dengan embedding code snippet yang relevan.


Mean Δ NDCG@10 Error Translasi

Kategori	OPUS+e5		OPUS+mE5		Gemma+e5		Gemma+mE5	
	Mean	n	Mean	n	Mean	n	Mean	n
omission	-0.388889	6	-0.317109	6	-1.000000	1	-1.000000	1
literal_translation	-0.234150	76	-0.112469	76	-0.157556	62	-0.031255	62
hallucination	-0.231424	488	-0.101165	488	-0.181523	479	-0.077118	479
terminology_error	-0.165825	68	-0.032465	68	-0.175792	81	-0.055059	81


Table: Mean Δ NDCG@10 per kategori error.




(a) OPUS + e5



(b) OPUS + mE5



(c) Gemma + e5



(d) Gemma + mE5

Korelasi dan Dampak Translasi

Model	Translator	Pearson Correlation (r)	Deskripsi
e5-base-v2	OPUS	-0.003	Hampir tidak ada korelasi
e5-base-v2	Gemma	-0.019	Hampir tidak ada korelasi
multilingual-e5	OPUS	0.019	Hampir tidak ada korelasi
multilingual-e5	Gemma	0.037	Hampir tidak ada korelasi

- ▶ Korelasi antara *embedding drift* dan $\Delta\text{NDCG@10}$ (translated vs English). Nilai r sangat mendekati 0, menunjukkan tidak ada hubungan linear yang berarti.
- ▶ Besar-kecilnya *drift* embedding relatif ke kueri Inggris tidak memprediksi seberapa besar NDCG@10 naik/turun.
- ▶ Kualitas code retrieval lebih dipengaruhi oleh *similarity* semantik kueri terjemahan dengan kode, bukan jarak embedding terhadap kueri asli.
- ▶ Ini menunjukkan bahwa translasi Gemma yang lebih natural dan semantik membuat embedding kueri lebih representatif dengan embedding kode meskipun memiliki *embedding drift* lebih besar

Kesimpulan

RQ1: Bagaimana performa Multilingual E5 Model dalam tugas Cross-Lingual Code Retrieval menggunakan kueri Bahasa Indonesia?

- ▶ Multilingual-E5 menunjukkan performa tinggi dan stabil pada skenario cross-lingual, dengan NDCG@10 yang hanya sedikit lebih rendah dari kueri Bahasa Inggris.
- ▶ Model ini robust terhadap variasi translasi, menghasilkan perbedaan kinerja yang lebih kecil dibanding e5-base-v2.
- ▶ Hal ini mengindikasikan bahwa representasi semantik yang dihasilkan Multilingual-E5 mampu menjembatani perbedaan bahasa tanpa kehilangan relevansi terhadap kode Python.

RQ2: Apakah metode translasi kueri berpengaruh dalam memaksimalkan performa Code Retrieval?

- ▶ Ya, metode translasi berdampak signifikan terhadap kualitas pencarian kode.
- ▶ Gemma menghasilkan NDCG@10 lebih tinggi dibanding OPUS, meskipun memiliki drift embedding yang lebih besar.
- ▶ Translasi yang alami dan tidak kaku lebih penting daripada translasi dengan kemiripan terdekat dengan embedding bahasa Inggris.
- ▶ Translasi literal (OPUS) cenderung menghasilkan kueri yang tidak koheren dan kurang similar dengan embedding pada dokumen (kode), sehingga menurunkan performa.

Implikasi Penelitian

- ▶ Model multilingual direkomendasikan untuk *cross-lingual code retrieval*.
- ▶ *LLM-assisted translation* (Gemma) lebih baik daripada *NMT literal translation* (OPUS).

Limitasi Penelitian

- ▶ Dataset CoSQA asli hanya menyediakan kueri Bahasa Inggris.
- ▶ Hasil translasi tidak mungkin mengungguli *ground-truth* English.

Appendix - Embedding Drift

- ▶ Untuk setiap kueri q dan model embedding m (misal: e5-base-v2 atau multilingual-e5):
 - ▶ $\mathbf{e}_{\text{EN}}^{(m)}(q)$ = embedding kueri Bahasa Inggris
 - ▶ $\mathbf{e}_{\text{TR}}^{(m)}(q, t)$ = embedding kueri hasil translasi dengan translator $t \in \{\text{OPUS, Gemma}\}$
- ▶ *Cosine similarity* antara dua vektor embedding $\mathbf{u}$ dan $\mathbf{v}$:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|^2 \|\mathbf{v}\|^2}$$

- ▶ *Embedding drift* didefinisikan sebagai jarak komplementer terhadap cosine similarity:

$$\text{drift}(q, m, t) = 1 - \cos\left(\mathbf{e}_{\text{EN}}^{(m)}(q), \mathbf{e}_{\text{TR}}^{(m)}(q, t)\right)$$

- ▶ Semakin besar nilai $\text{drift}(q, m, t)$, semakin jauh embedding kueri terjemahan dari embedding kueri Inggris untuk model m .

Appendix - Kategorisasi Error Translasi

```
def categorize_translation(en_query, id_translation):
    categories = []

    # 1. Terminology errors
    for term in technical_terms:
        if term in en_query.lower() and term not in id_translation.lower():
            categories.append("terminology_error")
            break

    # 2. Literal translation (example: very short translation)
    if len(id_translation.split()) < len(en_query.split()) - 1:
        categories.append("literal_translation")

    # 3. Omission (missing important keywords)
    en_keywords = ["sort", "reverse", "merge", "hash"]
    for kw in en_keywords:
        if kw in en_query.lower() and kw not in id_translation.lower():
            categories.append("omission")

    # 4. Hallucination (added words not in source)
    en_words = set(en_query.lower().split())
    id_words = set(id_translation.lower().split())
    extra_words = id_words - en_words
    if extra_words:
        categories.append("hallucination")

    return categories if categories else ["no_error"]
```

References

-  X. Li, K. Dong, Y. Q. Lee, W. Xia, Y. Yin, H. Zhang, Y. Liu, Y. Wang, R. Tang, ColR: A Comprehensive Benchmark for Code Information Retrieval Models, arXiv preprint arXiv:2407.02883, 2024. <https://doi.org/10.48550/arXiv.2407.02883>
-  J. Huang, D. Tang, L. Shou, M. Gong, K. Xu, D. Jiang, M. Zhou, N. Duan, CoSQA: 20,000+ Web Queries for Code Search and Question Answering, arXiv preprint arXiv:2105.13239, 2021. <https://doi.org/10.48550/arXiv.2105.13239>
-  X. Zhang, X. Ma, P. Shi, J. Lin, Mr. TyDi: A Multi-lingual Benchmark for Dense Retrieval, arXiv preprint arXiv:2108.08787, 2021. <https://doi.org/10.48550/arXiv.2108.08787>
-  L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, F. Wei, Multilingual E5 Text Embeddings: A Technical Report, arXiv preprint arXiv:2402.05672, 2024. <https://doi.org/10.48550/arXiv.2402.05672>
-  L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, F. Wei, Text Embeddings by Weakly-Supervised Contrastive Pre-training, arXiv preprint arXiv:2212.03533, 2024. <https://doi.org/10.48550/arXiv.2212.03533>