

Cross-Lingual Code Retrieval Bahasa Indonesia-Python berbasis Multilingual E5 Embedding

Perolehan Informasi Lanjut

Azhary Arliansyah ▪ Magister Ilmu Komputer - Universitas Indonesia



Outline

Problem Statement

Studi Literatur

Metodologi

Hasil Sementara

Problem Statement

- ▶ Alat pencarian konvensional (seperti *grep* atau fitur pencarian dasar pada IDE) hanya mengandalkan kecocokan leksikal (*string matching*)

Problem Statement

- ▶ Alat pencarian konvensional (seperti *grep* atau fitur pencarian dasar pada IDE) hanya mengandalkan kecocokan leksikal (*string matching*)
- ▶ Dokumentasi seringkali tidak lengkap, memaksa pengembang untuk mencari jawaban langsung di dalam *source code*

Problem Statement in Code Retrieval Research

- ▶ Belum tersedianya dataset yang berfokus pada penelitian *Code Retrieval* menggunakan kueri Bahasa Indonesia

Problem Statement in Code Retrieval Research

- ▶ Belum tersedianya dataset yang berfokus pada penelitian *Code Retrieval* menggunakan kueri Bahasa Indonesia
- ▶ Belum ada penelitian *Code Retrieval* menggunakan Bahasa Indonesia

Studi Literatur: CoIR Benchmark

- **CoIR (Code Information Retrieval) Benchmark** merupakan standar evaluasi yang komprehensif yang dirancang khusus untuk membandingkan kemampuan model dalam tugas *Code Retrieval* (Li et al., 2024)




Figure: CoIR Overview

Studi Literatur: CoIR Dataset (Li et al., 2024)

Main Task	Sub Task	Domain	Dataset	Language	#Query (train/dev/test)	#Corpus	L_{Query}	L_{Corpus}
Text-to-Code Retrieval	Code Contest Retrieval	Code Contest	APPS	py	5k/-/3.8K	9K	1.4K	575
	Web Query to Code Retrieval	Web query	CosQA	py	19k/-/500	21K	37	276
	Text to SQL Retrieval	Database	Synthetic Text2SQL	sql	100k/-/6K	106K	83	127
Code-to-Text Retrieval	Code Summary Retrieval	Github	CodeSearchNet	go, java, js php, py, ruby	905k/41k/53K	1M	594	156
Code-to-Code Retrieval	Code Context Retrieval	Github	CodeSearchNet-CCR [†]	go, java, js php, py, ruby	905k/41k/53K	1M	154	113
	Similar Code Retrieval	Deep Learning	CodeTrans Ocean-DL	py	564/72/180	816	1.6K	1.5K
		Contest	CodeTrans Ocean-Contest	c++, py	561/226/446	1K	770	1.5K
Hybrid Code Retrieval	Single-turn Code QA	Stack Overflow	StackOverflow QA [†]	miscellaneous	13k/3k/2K	20K	1.4K	1.2K
		Code Instruction	CodeFeedBack-ST	html, c, css, sql js, sql, py, shell ruby, rust, swift	125k/-/31K	156K	722	1.5K
	Multi-turn Code QA	Code Instruction	CodeFeedback-MT	miscellaneous	53k/-/13K	66K	4.4K	1.5K

Table 2: **Statistics of datasets** in CoIR benchmark. # is the quantity of query/corpus instances. $L_{(.)}$ refers to the average numbers of words per query/corpus. Datasets marked by [†] are created by us.

Studi Literatur: CoIR Baselines (Li et al., 2024)

Task (→)	Text-to-Code			Code-to-Text	Code-to-Code			Hybrid Code			Avg
Model (param.) ↓	Apps	CosQA	Synthetic Text2sql	Code SearchNet	Code SN-CCR	CodeTrans -Contest	-DL	StackOver Flow QA	CodeFeedBack -ST	-MT	
BM25	0.95	13.96	16.92	26.75	34.69	50.13	8.69	56.80	54.32	34.73	29.79
Contriever (110M)	5.14	14.21	45.46	34.72	35.74	44.16	24.21	66.05	55.11	39.23	36.40
E5-base (110M)	11.52	32.59	52.31	67.99	56.87	62.50	21.87	86.86	74.52	41.99	50.90
BGE-Base (110M)	4.05	32.76	45.59	69.60	45.56	38.50	21.71	73.55	64.99	31.42	42.77
GTE-Base (110M)	3.24	30.24	46.19	43.35	35.50	33.81	28.80	62.71	55.19	28.48	36.75
UniXcoder (123M)	1.36	25.14	50.45	60.20	58.36	41.82	31.03	44.67	36.02	24.21	37.33
BGE-M3 (567M)	7.37	22.73	48.76	43.23	47.55	47.86	31.16	61.04	49.94	33.46	39.31
E5-Mistral (7B)	21.33	31.27	65.98	54.25	65.27	82.55	33.24	91.54	72.71	33.65	55.18
OpenAI-Ada-002	8.70	28.88	58.32	74.21	69.13	53.34	26.04	72.40	47.12	17.74	45.59
Voyage-Code-002	26.52	29.79	69.26	81.79	73.45	72.77	27.28	87.68	65.35	28.74	56.26

Table 3: NDCG@10 score of various retrievers on CoIR. The best score is marked in boldface.

- ▶ **Model E5 (EmbEddings from bidirectional Encoder rEpresentations)** adalah salah satu dari *text embedding state-of-the-art* yang dirancang khusus untuk menghasilkan *general-purpose text embedding* yang dapat digunakan untuk berbagai tugas NLP, seperti *Information Retrieval*

- ▶ **Model E5 (EmbEddings from bidirectional Encoder rEpresentations)** adalah salah satu dari *text embedding state-of-the-art* yang dirancang khusus untuk menghasilkan *general-purpose text embedding* yang dapat digunakan untuk berbagai tugas NLP, seperti *Information Retrieval*
- ▶ E5 merupakan model pertama yang melampaui *baseline* BM25 pada BEIR Retrieval Benchmark (Wang et al., 2024)

- ▶ **Model E5 (EmbEddings from bidirectional Encoder rEpresentations)** adalah salah satu dari *text embedding state-of-the-art* yang dirancang khusus untuk menghasilkan *general-purpose text embedding* yang dapat digunakan untuk berbagai tugas NLP, seperti *Information Retrieval*
- ▶ E5 merupakan model pertama yang melampaui *baseline* BM25 pada BEIR Retrieval Benchmark (Wang et al., 2024)
- ▶ Dilatih secara *contrastive*, memaksimalkan kesamaan vektor kueri dan dokumen yang relevan, sambil meminimalkan kesamaan dengan dokumen yang tidak relevan

- ▶ **Model E5 (EmbEddings from bidirectional Encoder rEpresentations)** adalah salah satu dari *text embedding state-of-the-art* yang dirancang khusus untuk menghasilkan *general-purpose text embedding* yang dapat digunakan untuk berbagai tugas NLP, seperti *Information Retrieval*
- ▶ E5 merupakan model pertama yang melampaui *baseline* BM25 pada BEIR Retrieval Benchmark (Wang et al., 2024)
- ▶ Dilatih secara *contrastive*, memaksimalkan kesamaan vektor kueri dan dokumen yang relevan, sambil meminimalkan kesamaan dengan dokumen yang tidak relevan
- ▶ Memiliki arsitektur Bi-Encoder, untuk *encode* kueri dan *encode* dokumen

- ▶ E5 dilatih dari CCPairs (Colossal Clean text Pairs), yaitu dataset pasangan teks skala web yang dikurasi dengan sinyal pelatihan heterogen

Studi Literatur: E5 - Contrastive CCPairs

- ▶ E5 dilatih dari CCPairs (Colossal Clean text Pairs), yaitu dataset pasangan teks skala web yang dikurasi dengan sinyal pelatihan heterogen
- ▶ Sumber data meliputi pasangan (post, comment) dari Reddit, (question, upvoted answer) dari Stackexchange, (title, abstract) dari Scientific papers, dan lainnya

Studi Literatur: E5 - Contrastive CCPairs

- ▶ E5 dilatih dari CCPairs (Colossal Clean text Pairs), yaitu dataset pasangan teks skala web yang dikurasi dengan sinyal pelatihan heterogen
- ▶ Sumber data meliputi pasangan (post, comment) dari Reddit, (question, upvoted answer) dari Stackexchange, (title, abstract) dari Scientific papers, dan lainnya
- ▶ Menggunakan fungsi InfoNCE untuk menghitung loss pada *contrastive pre-training*

Studi Literatur: E5 - InfoNCE

- ▶ Contrastive pre-training bertujuan untuk mengajarkan model embedding cara membedakan antara pasangan teks yang relevan (positif) dan tidak relevan (negatif)

InfoNCE Contrastive Loss

$$\min L_{\text{cont}} = -\frac{1}{N} \sum_{i=1}^N \log \left(\frac{e^{(s_{\theta}(q_i, p_i))}}{e^{(s_{\theta}(q_i, p_i))} + \sum_j e^{(s_{\theta}(q_i, p_{ij}^-))}} \right)$$

Dimana $s_{\theta}(p, q)$ merupakan cosine similarity yang memiliki skala temperatur τ

$$s_{\theta}(p, q) = \cos(E_p, E_q) / \tau$$

Studi Literatur: Multilingual E5 Text Embeddings (Wang et al., 2024)

- ▶ E5 yang dilatih menggunakan data campuran yang beragam dari pasangan teks multibahasa, mencakup sekitar 1 miliar text pairs

Studi Literatur: Multilingual E5 Text Embeddings (Wang et al., 2024)

- ▶ E5 yang dilatih menggunakan data campuran yang beragam dari pasangan teks multibahasa, mencakup sekitar 1 miliar text pairs
- ▶ Dirancang berdasarkan arsitektur yang sama dengan XLM-RoBERTa

Studi Literatur: Multilingual E5 Text Embeddings (Wang et al., 2024)

- ▶ E5 yang dilatih menggunakan data campuran yang beragam dari pasangan teks multibahasa, mencakup sekitar 1 miliar text pairs
- ▶ Dirancang berdasarkan arsitektur yang sama dengan XLM-RoBERTa
- ▶ Sumber data untuk *pre-training* mencakup Wikipedia, mC4, Multilingual CC News, NLLB, Reddit, S2ORC, Stackexchange, dan xP3

Studi Literatur: Multilingual E5 Text Embeddings (Wang et al., 2024)

- ▶ E5 yang dilatih menggunakan data campuran yang beragam dari pasangan teks multibahasa, mencakup sekitar 1 miliar text pairs
- ▶ Dirancang berdasarkan arsitektur yang sama dengan XLM-RoBERTa
- ▶ Sumber data untuk *pre-training* mencakup Wikipedia, mC4, Multilingual CC News, NLLB, Reddit, S2ORC, Stackexchange, dan xP3
- ▶ Mr. TyDi (Zhang et al., 2021) merupakan salah satu dataset yang digunakan untuk *fine-tuning*, yang secara eksplisit mencakup Bahasa Indonesia

Studi Literatur: Multilingual E5 Text Embeddings (Wang et al., 2024)

- ▶ E5 yang dilatih menggunakan data campuran yang beragam dari pasangan teks multibahasa, mencakup sekitar 1 miliar text pairs
- ▶ Dirancang berdasarkan arsitektur yang sama dengan XLM-RoBERTa
- ▶ Sumber data untuk *pre-training* mencakup Wikipedia, mC4, Multilingual CC News, NLLB, Reddit, S2ORC, Stackexchange, dan xP3
- ▶ Mr. TyDi (Zhang et al., 2021) merupakan salah satu dataset yang digunakan untuk *fine-tuning*, yang secara eksplisit mencakup Bahasa Indonesia
- ▶ Performa melampaui mDPR pada MIRACL benchmark, dan melampaui LaBSE pada Bitext Mining

Research Questions

- ▶ RQ1: Bagaimana performa Multilingual E5 Model dalam tugas Cross-Lingual Code Retrieval dalam pencarian kode Python menggunakan kueri Bahasa Indonesia?

Research Questions

- ▶ RQ1: Bagaimana performa Multilingual E5 Model dalam tugas Cross-Lingual Code Retrieval dalam pencarian kode Python menggunakan kueri Bahasa Indonesia?
- ▶ RQ2: Apakah metode translasi kueri berpengaruh dalam memaksimalkan performa Code Retrieval?

Alur Metodologi




Dataset
CoSQA


Alur Metodologi




Alur Metodologi



Alur Metodologi



Alur Metodologi



Metodologi: Dataset

- ▶ Dataset yang akan digunakan adalah **CoSQA** (Huang et al., 2021), yang digunakan untuk *text-to-code retrieval*
- ▶ qrels terdiri dari **19k training**, dan **500 testing**
- ▶ Bahasa pemrograman pada dataset tersebut adalah **Python**
- ▶ Kueri pada dataset tersebut berbahasa Inggris

Example 1:
Query: python check if path is absolute path or relative path
Code:

```
def is_relative_url(url):  
    """simple method to determine if a url is relative or absolute"""  
    if url.startswith("#"):  
        return None  
    if url.find(":/") > 0 or url.startswith("/"): # either 'http(s)://...' or '//cdn...' and therefore absolute  
        return False  
    return True
```

Label: 1

Example 2:
Query: capitalize letters in string python
Code:

```
def snake_to_camel(s: str) -> str:  
    """ Convert string from snake case to camel case. """  
    fragments = s.split("_")  
    return fragments[0] + ".join(x.title() for x in fragments[1:])
```

Label: 0

Figure: Contoh Data CoSQA

Metodologi: Model

- ▶ Menggunakan Multilingual E5 Model sebagai text embeddings
- ▶ Menerjemahkan kueri ke Bahasa Indonesia menggunakan:
 - ▶ Open-Source Neural Machine Translation Model: **opus-mt-en-id**
 - ▶ LLM: Gemma 2, menggunakan instruksi (prompt) untuk menerjemahkan kueri
- ▶ Menggunakan **coir-eval** library yang dirancang khusus untuk evaluasi Code Retrieval, yang menggunakan metrik evaluasi nDCG, mAP, Recall, dan Precision

Contoh Prompt: *"Anda adalah penerjemah ahli untuk kueri pencarian kode. Terjemahkan kueri bahasa Inggris berikut ke dalam Bahasa Indonesia yang alami dan sering digunakan untuk mencari kode. Jawab hanya dengan terjemahan Bahasa Indonesia. Kueri: 'How to calculate the average of a list in Python?'"*

Metodologi: Contoh Keluaran Hasil coir-eval

Metric	@1	@3	@5	@10	@100	@1000
NDCG	0.152	0.224	0.276	0.332	0.403	0.414
MAP	0.152	0.205	0.234	0.258	0.272	0.273
Recall	0.152	0.280	0.406	0.578	0.908	0.992
Precision	0.152	0.093	0.081	0.058	0.009	0.001

Metodologi: Ablation Study

- ▶ Membandingkan performa model E5-base dengan Multilingual E5
- ▶ Membandingkan performa model dengan dan tanpa translasi kueri
- ▶ Membandingkan performa model dengan kueri yang ditranslasi dengan opus-mt-en-id dan Gemma 2
- ▶ Hasil yang diharapkan bisa dianalisa:
 - ▶ Komponen apa yang berkontribusi terhadap performa: translation atau embeddings?
 - ▶ Apakah model multilingual sangat berpengaruh terhadap performa?

Hasil Sementara: Eksperimen

```
device = 'cuda'
model_name = 'intfloat/e5-base-v2'

class YourCustomDEModel:
    def __init__(self, model_name='intfloat/e5-base-v2', **kwargs):
        self.tokenizer = AutoTokenizer.from_pretrained(model_name)
        self.model = AutoModel.from_pretrained(model_name).to(device)
        self.model_name = model_name
        self.tokenizer.add_eos_token = False
```

Figure: Load Model E5

```
# Load the model
model = YourCustomDEModel()

task = 'cosqa'

# Get tasks
# all task ["codetrans-dl", "stackoverflow-qa", "apps", "codefeedback-mt", "codefeedback-st", "codetrans-contest", "synthetic-
# text2sql", "cosqa", "codesearchnet", "codesearchnet-ccr"]
tasks = coir.get_tasks(tasks=[task])

with open(f'{task}.json', 'w', encoding='utf-8') as f:
    json.dump(tasks, f, indent=2, ensure_ascii=False)

print("✅ Saved to tasks.json")

# Initialize evaluation
evaluation = COIR(tasks=tasks, batch_size=128)

# Run evaluation
results = evaluation.run(model, output_folder=f'results/{model_name}')
print(results)

20604/? [00:00<00:00, 8823.76it/s]
✅ Saved to tasks.json
```

Figure: Evaluasi Model

Hasil Sementara: Eksperimen

```
top_n = 5
print(f'✅ Top {top_n} search results for query: '{search_query[0]}'\n")
print("-" * 60)

# 4. Iterate through the top indices and display the result.
for rank, index in enumerate(ranked_indices[:top_n]):
    score = similarity_scores[index]
    # Retrieve the actual document dictionary using the index
    document = code_corpus[index]

    # In the original data, the document IDs (d1, d2, etc.) are lost in 'list(corpus_dictionary.values())'.
    # To recover the key/ID, you would need the original dictionary, but we can't easily
    # recover it from the list here. We'll just display the rank and score.

    print(f'Rank {rank+1} (Similarity Score: {score:.4f}):')

    # Display the actual code snippet
    # Only display the first few lines to keep the output readable
    snippet_lines = document['text'].split('\n')
    print("Code Snippet:")
    print('\n'.join(snippet_lines[:5]) + ('...' if len(snippet_lines) > 5 else ''))
    print("-" * 60)
```

Encoding batches: 100%  1/1 [00:00<00:00, 42.17batch/s]

✅ Top 5 search results for query: 'sorted_by'

Rank 1 (Similarity Score: 0.8553):

Code Snippet:

```
def sorted_by(key: Callable[[raw_types.Qid], Any]) -> 'QubitOrder':
    """A basis that orders qubits ascending based on a key function.

    Args:
        key: A function that takes a qubit and returns a key value. The...
```

Rank 2 (Similarity Score: 0.8511):

Code Snippet:

```
def sort_by_name(self):
    """Sort list elements by name."""
    sorted_qubits = sorted(self.qubits, key=lambda q: q.name)
```

Figure: Retrieve Code

Hasil Sementara: E5-base-v2 Tanpa Proses Translasi

- ▶ Hasil melampaui baseline ColR Benchmark yang menggunakan E5-base (v1) pada CoSQA
- ▶ Peningkatan terjadi pada nDCG@10 dari **32.59 ke 33.2**
- ▶ v2 dilatih menggunakan korpus yang lebih besar dibandingkan dengan v1

Metric	@1	@3	@5	@10	@100	@1000
NDCG	0.152	0.224	0.276	0.332	0.403	0.414
MAP	0.152	0.205	0.234	0.258	0.272	0.273
Recall	0.152	0.280	0.406	0.578	0.908	0.992
Precision	0.152	0.093	0.081	0.058	0.009	0.001

References

-  X. Li, K. Dong, Y. Q. Lee, W. Xia, Y. Yin, H. Zhang, Y. Liu, Y. Wang, R. Tang, ColR: A Comprehensive Benchmark for Code Information Retrieval Models, arXiv preprint arXiv:2407.02883, 2024. <https://doi.org/10.48550/arXiv.2407.02883>
-  J. Huang, D. Tang, L. Shou, M. Gong, K. Xu, D. Jiang, M. Zhou, N. Duan, CoSQA: 20,000+ Web Queries for Code Search and Question Answering, arXiv preprint arXiv:2105.13239, 2021. <https://doi.org/10.48550/arXiv.2105.13239>
-  X. Zhang, X. Ma, P. Shi, J. Lin, Mr. TyDi: A Multi-lingual Benchmark for Dense Retrieval, arXiv preprint arXiv:2108.08787, 2021. <https://doi.org/10.48550/arXiv.2108.08787>
-  L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, F. Wei, Multilingual E5 Text Embeddings: A Technical Report, arXiv preprint arXiv:2402.05672, 2024. <https://doi.org/10.48550/arXiv.2402.05672>
-  L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, F. Wei, Text Embeddings by Weakly-Supervised Contrastive Pre-training, arXiv preprint arXiv:2212.03533, 2024. <https://doi.org/10.48550/arXiv.2212.03533>